Lab 9 · Series de tiempo y forecasting

Diego Rosales 23258 Juan Francisco Martínez 23617

1. Datos y protocolo común

Se pronostican las siguientes 24 horas de electricidad de 150 clientes portugueses. El panel contiene 26,304 horas por cliente (2012–2014); los clientes y seed=42 coinciden en todas las familias. Cada registro de 15 min representa kW al final del intervalo: se suma con peso 0.25 y etiquetas horarias a la izquierda para obtener kWh/h.

Train termina el 30/06/2014, validación abarca julio–septiembre y prueba octubre–diciembre. Cada modelo base tiene un único backtest de 92 orígenes a medianoche: 331,200 predicciones. Las ventanas usan L=168, H=24 y stride de entrenamiento 1 h. El z-score de las redes y la escala del MASE se calculan con train; LightGBM reajusta su escalado con la historia que recibe, sin fechas futuras. El reajuste final incluye train+validación, con presupuesto elegido en validación.

El código existente interpola la hora de marzo y divide por dos la hora sumada de octubre. Se conserva esta transformación en B para mantener compatibilidad con los resultados de A; difiere del borrador PLAN.md, que proponía conservar la suma de octubre. Calendario futuro: hora, día y mes cíclicos, y feriados nacionales portugueses.

2. Fundamentos y auditoría

LSTM devuelve la secuencia de estados y el estado final (h,c); GRU usa solo h. La cabeza directa emite 24 valores; la estrategia recursiva aprende un paso y realimenta sus propias salidas. Seq2seq separa encoder y decoder, agrega calendario conocido y usa teacher forcing de 0.5 solo en train; validación y prueba decodifican sin etiquetas futuras. RevIN normaliza cada ventana y revierte su salida con estadísticos de esa misma entrada.

Una TCN usa convoluciones causales dilatadas. Con kernel 3 y dilataciones 1,2,4,8,16,32, la implementación instalada usa una convolución por nivel y cubre 127 posiciones: $R=1+\Sigma(k-1)d$. Conv1d recibe (batch, canales, tiempo). Un TransformerEncoderLayer combina atención y MLP; requiere posición explícita para distinguir el orden temporal. iTransformer atiende entre clientes y PatchTST entre parches de tiempo.

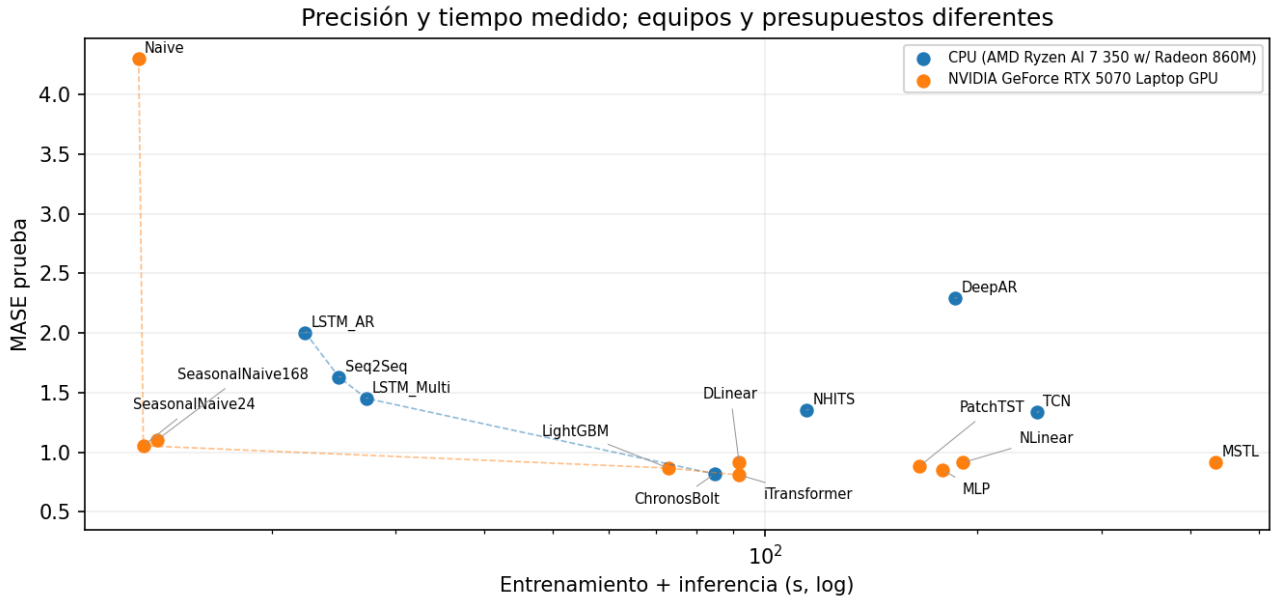
Se auditan cuatro fugas: normalizar con toda la serie, desalinear calendario, dividir ventanas aleatoriamente y usar test para early stopping. La historia se corta en origin−1 h. El contrato rechaza claves duplicadas, clientes/horizontes incompletos, valores no finitos y cruces de cuantiles. SeasonalNaive24 coincide exactamente con StatsForecast.cross_validation en los 92 orígenes de un cliente de control, con refit=False y step_size=24.

3. Comparación de modelos

Se completaron 17 modelos base. El menor MASE de prueba fue iTransformer: 0.809, MAE=56.59 kWh, WAPE=7.2%. Esta clasificación describe la prueba; no se usó para elegir hiperparámetros.

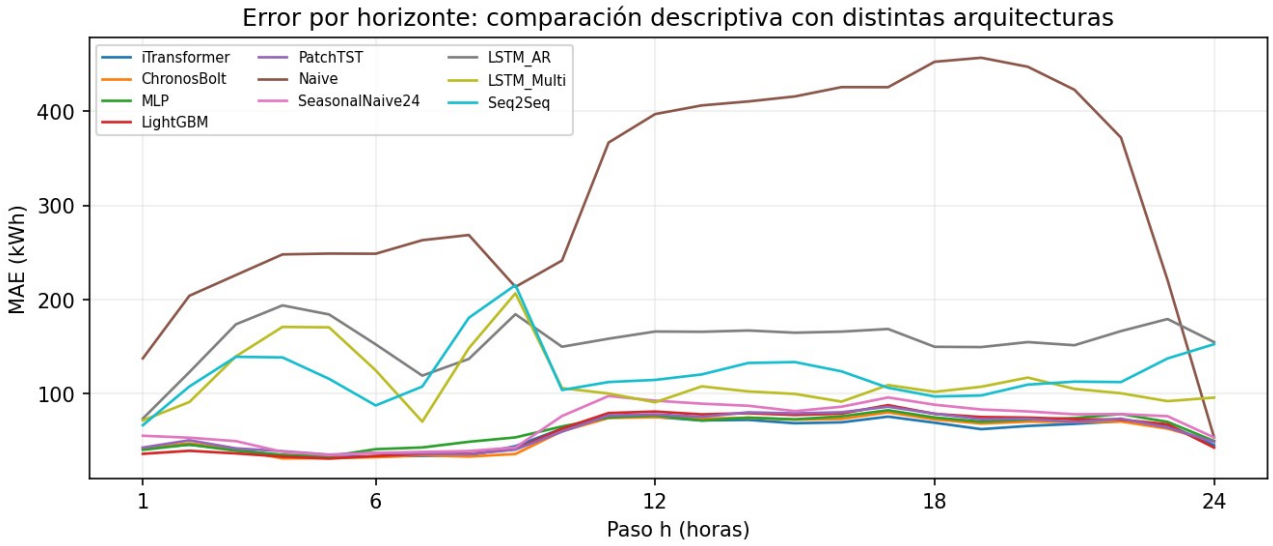
Modelo	MAE	RMSE	WAPE	MASE	Train s	Infer s	Equipo
iTransformer	56.588	504.324	0.072	0.809	75.656	16.309	RTX5070
ChronosBolt	57.195	499.019	0.073	0.818	0.000	84.807	CPU
MLP	60.872	526.179	0.078	0.852	164.607	13.741	RTX5070
LightGBM	59.511	526.230	0.076	0.867	48.248	24.734	RTX5070
PatchTST	60.516	525.857	0.077	0.882	148.286	17.175	RTX5070
NLinear	65.602	610.082	0.084	0.913	172.415	18.147	RTX5070
DLinear	65.155	603.205	0.083	0.914	77.410	14.470	RTX5070
MSTL	65.824	571.294	0.084	0.917	0.000	434.966	RTX5070
SNaive24	67.915	546.489	0.087	1.055	0.000	13.163	RTX5070
SNaive168	80.020	887.800	0.102	1.106	0.000	13.786	RTX5070
TCN	100.360	854.809	0.128	1.333	209.264	33.540	CPU
NHITS	96.079	765.285	0.123	1.353	83.498	30.962	CPU
LSTM_Multi	113.257	884.602	0.145	1.452	13.334	13.898	CPU
Seq2Seq	121.795	937.636	0.156	1.630	16.664	8.255	CPU
LSTM_AR	156.284	1165.875	0.200	2.004	12.539	9.775	CPU
DeepAR	184.351	1488.052	0.236	2.292	154.044	31.722	CPU
Naive	315.443	2369.997	0.404	4.298	0.000	12.966	RTX5070

Parámetros totales/entrenables, covariables, estrategia, memoria y tiempos completos: outputs/tables/comparacion.csv y outputs/results/*.json. LightGBM cuenta nodos, no pesos neuronales; el hardware heredado identifica el equipo y no implica entrenamiento GPU de árboles. En MSTL, inferencia incluye ajustes por origen sobre ocho semanas.

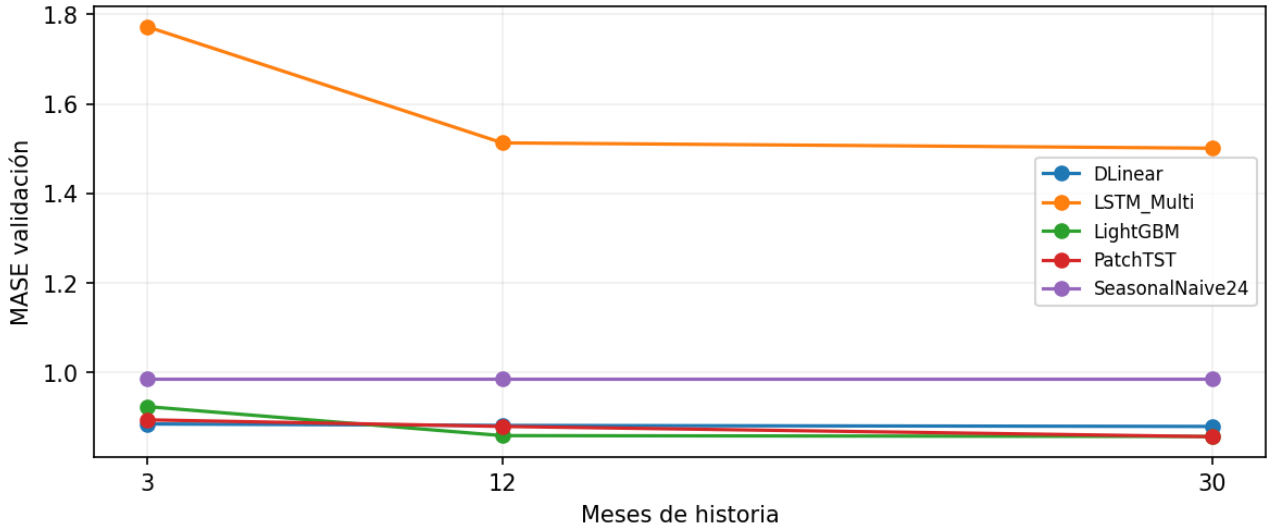


Los tiempos de A se midieron en RTX 5070 y los de B en AMD Ryzen AI 7 350 (CPU). B usó redes menores y presupuestos limitados explícitos; esta figura no permite concluir qué arquitectura sería más rápida con el mismo equipo y presupuesto.

4. Estrategias y sensibilidad



La recursión puede acumular error al reutilizar predicciones. La salida directa evita esta realimentación; seq2seq comparte dinámica entre pasos y admite calendario del decoder. Las curvas comparan arquitecturas y presupuestos diferentes, por lo que no aíslan causalmente el efecto de la estrategia.



Para el mejor recurrente por validación, se ensayaron L=48/168/336 y 3/12/30 meses. La configuración con menor MASE de este barrido fue L=48, 30 meses: 1.494. El barrido se reporta en validación y no implica una segunda selección sobre prueba. Los experimentos de A conservan sus registros originales.

En los baselines, L se interpreta según sus rezagos: SeasonalNaive24 no cambia para L≥24; LightGBM con rezagos fijos 1–24,168 no cambia entre L=168 y 336. Para L=48 se mide una ablación sin el rezago 168. Los valores y su procedencia están en baseline_L.csv.

alcance	MAE	MASE	train_s	params
global_150_evaluado_10	117.871	1.623	7.826	22728
local_10	130.114	1.815	22.193	227280

Local: diez redes separadas; global: una red entrenada con los 150 clientes y evaluada sobre los mismos diez IDs fijados con seed=42. La evaluación de este experimento es validación. El presupuesto por cliente y el volumen de datos difieren; se informa el costo total de los diez ajustes.

5. Incertidumbre, estabilidad y actualización

Modelo	Pinball .1	Pinball .5	Pinball .9	Cobertura .1–.9
ChronosBolt	14.290	28.597	14.023	0.812
DeepAR	36.769	92.275	47.473	0.712

La pérdida pinball penaliza asimétricamente los residuos según τ. El intervalo P10–P90 tiene cobertura nominal de 80%; se mide frecuencia real de inclusión. MASE promedia por cliente el MAE dividido por el MAE estacional de train; WAPE divide la suma de errores absolutos entre consumo absoluto total y enfatiza clientes grandes. El MAPE omite $|y|\leq 0.001$ y no se interpreta sin esa exclusión.

DeepAR aprende una distribución Normal sobre valores normalizados y obtiene cuantiles mediante trayectorias. Chronos-Bolt-small funciona zero-shot en CPU y devuelve (series, horizonte, cuantiles); se reordenan q10/q50/q90 por hora para evitar cruces y se usa q50 como pronóstico puntual. No se demuestra que Electricity estuviera excluido de su preentrenamiento; su evaluación externa puede contener contaminación.

Tres semillas con configuración y presupuesto CPU iguales: MASE promedio 0.898, desviación estándar muestral 0.008. La selección del modelo y del presupuesto se fijó con validación. Una media de tres réplicas no constituye un intervalo de confianza robusto.

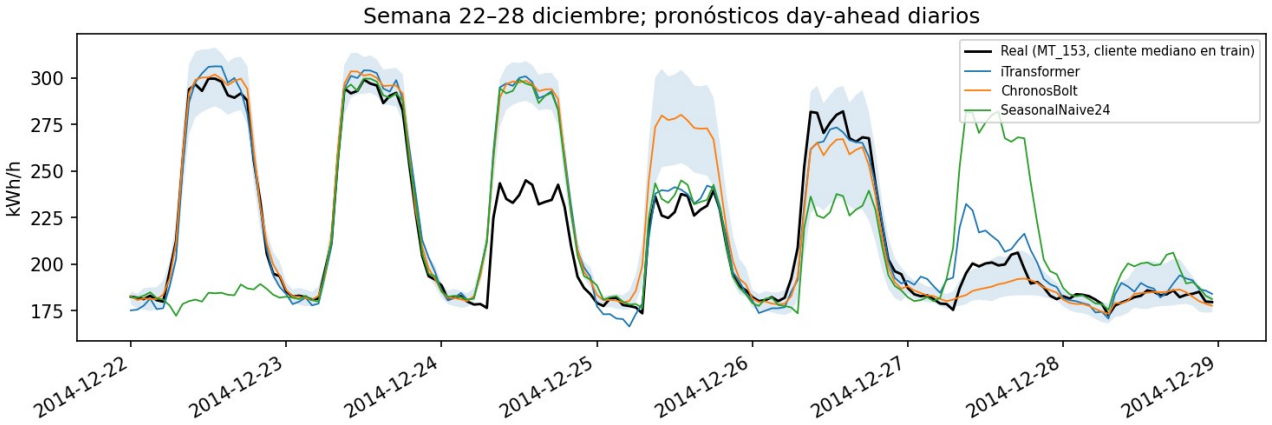
modelo	seed	MAE	MASE	train_s
iTransformer_seed123	123	60.800	0.888	107.100
iTransformer_seed7	7	62.681	0.901	106.114
iTransformer_seed42	42	63.742	0.904	99.368

La actualización mensual reentrena al inicio de octubre, noviembre y diciembre con historia anterior al mes. Hiperparámetros y pasos quedan congelados; el escalado del DL permanece ajustado a train. La referencia fija del DL es la réplica CPU seed=42, con igual arquitectura y presupuesto, no la corrida original de A.

modelo	MAE	MASE	MASE_navidad	train_s	inference_s
LightGBM_mensual	59.524	0.868	1.616	270.994	25.455
iTransformer_mensual	63.131	0.911	1.760	317.668	8.863

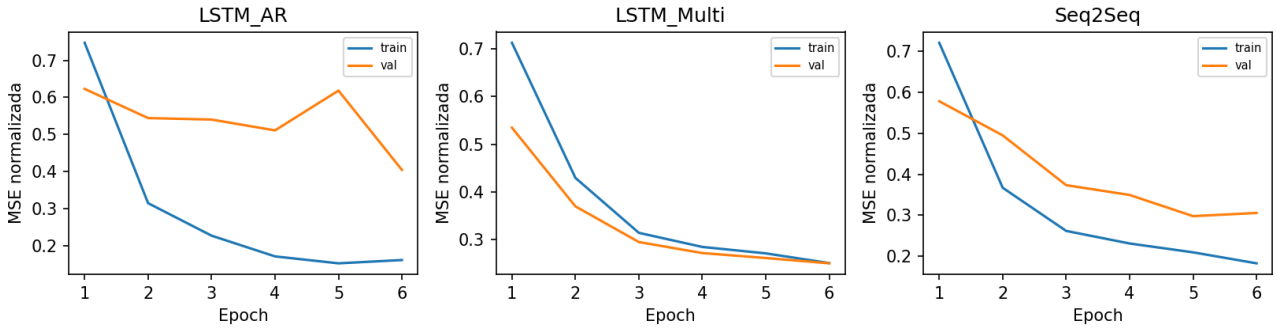
LightGBM: MASE fijo 0.867 → mensual 0.868 (Δ=+0.001).

iTransformer: MASE fijo 0.904 → mensual 0.911 (Δ=+0.007).



6. Discusión, reproducibilidad y referencias

En Navidad (22–28 diciembre), el menor MASE fue iTransformer: 1.386. Los horarios festivos difieren de días laborales y elevan el error de modelos que dependen de periodicidad. La figura usa el cliente de consumo medio mediano en train; no fue elegido por un error favorable en test.



Las curvas de tres recurrentes muestran convergencia y brecha de generalización. En CPU se acotó cada epoch a una muestra reproducible de 50 batches de 128 ventanas, hasta 6 epochs; el barrido mantiene ese mismo máximo y los modelos locales usan un presupuesto menor. Se conserva stride=1 en las ventanas y evaluación completa de 150 clientes. N-HiTS, TCN y DeepAR usan hasta 250 pasos y refit con el paso seleccionado. Los límites exactos quedan en cada JSON.

Los pronósticos preservan unique_id, ds, origin, modelo, y_hat y cuantiles cuando corresponden. outputs/forecasts/todos.parquet reúne las corridas. main.ipynb carga artefactos guardados y se ejecuta de principio a fin sin reentrenar. python -m src.run_cisco --stage all reanuda modelos faltantes. requirements-cpu-lock.txt registra el entorno ejecutado. Las pruebas automatizadas verifican aislamiento de etiquetas futuras y el contrato del backtest.

Límites: presupuestos y hardware heterogéneos; muestras de batches en entrenamiento; incertidumbre externa de preentrenamiento Chronos; comparación local/global con distinto volumen de información; selección de clientes completos usa disponibilidad del panel entero. No se extrapola la clasificación a clientes nuevos ni se atribuyen diferencias de tiempo exclusivamente al modelo.

Referencias técnicas consultadas: PyTorch, nn.LSTM/nn.GRU y TransformerEncoderLayer (docs.pytorch.org); Nixtla, código de NeuralForecast y StatsForecast (github.com/Nixtla); Amazon Science, chronos-forecasting y modelo chronos-bolt-small (huggingface.co/amazon/chronos-bolt-small); UCI ElectricityLoadDiagrams20112014 (archive.ics.uci.edu/dataset/321). En informe/investigacion.md se amplían las notas y enlaces primarios.

Repositorio: https://github.com/diegoanro22/DL-LAB09